

SSISTEM KLASIFIKASI DAN MONITORING AKTIVITAS FISIK REAL-TIME BERBASIS RANDOM FOREST UNTUK PERILAKU SEDENTARY

Virdio Samuel Saragih^{1*}; Dona Maya²; Givaro Ananta³; Romauli Silaban⁴; Syahrialdi Rachim Akbar⁵

Program Studi Sains Data¹
Institut Teknologi Sumatera, Lampung Selatan, Indonesia¹
Author Institution Website Address¹
Author's E-mail^{1*}

Author Study Program² (if different institutions with author 1 separated)
Name of Author Institution, City, Country² (if different institutions with Author 1 separated)
Author Institution Website Address² (if different institutions with author 1 separated)
Author's E-mail² (if different institutions from Author 1 are separated)

(*) Corresponding Author
(Responsible for the Quality of Paper Content)



The creation is distributed under the Creative Commons Attribution-NonCommercial 4.0 International License.

Abstract—Sedentary behavior is a health-related concern because prolonged physical inactivity may increase the risk of chronic diseases and reduce physical well-being. This study develops a real-time physical activity classification and monitoring system using wearable sensor data and the Random Forest algorithm. The system processes raw sensor data collected from multiple body positions, extracts statistical features, and classifies user activities into predefined categories, namely sedentary, light, and intense activity. The implemented system adopts a streaming-based Kappa Architecture by integrating MQTT, Kafka, Spark Structured Streaming, MinIO, PostgreSQL, and Tableau to support real-time data acquisition, activity classification, data storage, and dashboard visualization. A key contribution of this system is the calculation of sedentary duration using the original sensor timestamp rather than the database storage timestamp, thereby reducing inaccuracies caused by processing latency in the machine learning pipeline. The classification results are stored in an operational real-time table for direct monitoring, while aggregated data are transformed into a PostgreSQL data mart to support historical activity analytics. The results show that the system is able to classify physical activities in real time, monitor sedentary duration, generate alerts when sedentary behavior exceeds a predefined threshold, and provide dashboard-based insights for both real-time monitoring and historical analysis.

Keywords—Human Activity Recognition, Random Forest, Sedentary Behavior, Wearable Sensors, Real-Time Monitoring.

Intisari—Perilaku sedentari merupakan salah satu permasalahan kesehatan karena aktivitas fisik yang rendah dalam waktu lama dapat meningkatkan risiko penyakit kronis dan menurunkan kondisi kesehatan fisik. Penelitian ini mengembangkan sistem klasifikasi dan pemantauan aktivitas fisik secara real-time menggunakan data sensor wearable dan algoritma Random Forest. Sistem memproses data sensor mentah yang diperoleh dari beberapa posisi tubuh, melakukan ekstraksi fitur statistik, dan mengklasifikasikan aktivitas pengguna ke dalam kategori sedentary, light, dan intense. Sistem yang dibangun menerapkan arsitektur streaming berbasis Kappa Architecture dengan mengintegrasikan MQTT, Kafka, Spark Structured Streaming, MinIO, PostgreSQL, dan Tableau untuk mendukung akuisisi data real-time, klasifikasi aktivitas, penyimpanan data, serta visualisasi dashboard. Salah satu kontribusi utama sistem ini adalah perhitungan durasi sedentari menggunakan timestamp asli dari sensor, bukan timestamp penyimpanan ke database, sehingga kesalahan perhitungan akibat latensi proses machine learning dapat dikurangi. Hasil klasifikasi disimpan pada tabel operasional real-time untuk kebutuhan monitoring langsung, sedangkan data agregasi ditransformasikan ke dalam data mart PostgreSQL untuk mendukung

analisis historis. Hasil implementasi menunjukkan bahwa sistem mampu mengklasifikasikan aktivitas fisik secara real-time, memantau durasi sedentari, menghasilkan alert ketika durasi sedentari melebihi ambang batas, serta menyediakan insight melalui dashboard untuk kebutuhan monitoring real-time dan analisis historis.

Kata Kunci—Human Activity Recognition, Random Forest, Perilaku Sedentari, Sensor Wearable, Pemantauan Real-Time.

PENDAHULUAN

Perkembangan teknologi perangkat wearable dan Internet of Things (IoT) telah mendorong pemanfaatan data sensor untuk mendukung sistem pemantauan kesehatan secara berkelanjutan. Sensor seperti accelerometer, gyroscope, dan magnetometer yang tertanam pada perangkat wearable mampu merekam pergerakan pengguna dalam bentuk data deret waktu. Data tersebut dapat digunakan untuk mengenali aktivitas fisik pengguna, seperti duduk, berdiri, berjalan, berlari, maupun berbaring, sehingga berpotensi mendukung pengembangan sistem pemantauan kesehatan dan kebugaran berbasis data [5], [6].

Salah satu isu kesehatan yang menjadi perhatian adalah perilaku sedentari, yaitu kondisi ketika seseorang melakukan aktivitas dengan pengeluaran energi rendah dalam durasi tertentu, seperti duduk atau berbaring terlalu lama. Perilaku sedentari yang berlangsung dalam waktu panjang dapat meningkatkan risiko gangguan kesehatan, seperti obesitas, diabetes melitus tipe 2, penyakit kardiovaskular, dan gangguan metabolisme lainnya [1]. Oleh karena itu, dibutuhkan sistem yang tidak hanya mampu mengenali aktivitas fisik pengguna, tetapi juga mampu memantau durasi perilaku sedentari secara real-time dan memberikan peringatan ketika durasi tersebut melewati ambang batas tertentu.

Pengenalan aktivitas manusia atau Human Activity Recognition (HAR) merupakan pendekatan yang digunakan untuk mengubah data sensor mentah menjadi informasi aktivitas yang lebih bermakna. Dalam konteks wearable sensor, HAR memanfaatkan pola pergerakan tubuh yang terekam oleh sensor untuk mengklasifikasikan aktivitas pengguna. Data sensor yang digunakan dalam penelitian ini berasal dari beberapa posisi tubuh, yaitu torso (T), right arm (RA), left arm (LA), right leg (RL), dan left leg (LL). Setiap posisi sensor menghasilkan data accelerometer, gyroscope, dan magnetometer pada sumbu x, y, dan z, sehingga data mentah terdiri atas 45 atribut sensor. Untuk meningkatkan kualitas representasi data, atribut mentah tersebut diekstraksi menjadi fitur statistik seperti mean, standard deviation, minimum,

maximum, skewness, dan kurtosis, sehingga menghasilkan fitur yang lebih sesuai untuk proses klasifikasi.

Machine learning berperan penting dalam proses klasifikasi aktivitas fisik berbasis sensor. Salah satu algoritma yang banyak digunakan dalam penelitian HAR adalah Random Forest. Random Forest merupakan metode ensemble learning yang membangun sejumlah decision tree dan menggabungkan hasil prediksinya untuk menghasilkan klasifikasi yang lebih stabil. Algoritma ini memiliki keunggulan dalam menangani data berdimensi tinggi serta relatif tahan terhadap noise pada data sensor. Penelitian Balli et al. menunjukkan bahwa Random Forest mampu memberikan performa yang baik dalam klasifikasi aktivitas manusia berbasis data sensor smartwatch [2]. Selain itu, studi terkait HAR berbasis wearable juga menunjukkan bahwa pendekatan machine learning masih relevan untuk pengenalan aktivitas fisik dalam berbagai skenario penggunaan [5], [6].

Selain akurasi klasifikasi, sistem pemantauan aktivitas fisik juga membutuhkan kemampuan pemrosesan data secara real-time. Pada lingkungan IoT, data sensor dikirim secara periodik dan harus diproses segera agar informasi yang dihasilkan tetap merepresentasikan kondisi aktual pengguna [3]. Dalam penelitian ini, sistem dibangun menggunakan pendekatan Kappa Architecture karena alur utama pemrosesan data berbasis streaming. Data sensor dikirim melalui MQTT, diteruskan ke Kafka, diproses menggunakan Spark Structured Streaming, disimpan pada MinIO sebagai data lake, kemudian ditransformasikan ke PostgreSQL sebagai data mart untuk kebutuhan analisis dan visualisasi. Pendekatan ini memungkinkan data yang masuk diproses secara berkelanjutan dari tahap akuisisi, klasifikasi aktivitas, penyimpanan, hingga visualisasi dashboard.

Penelitian terkait pemantauan perilaku sedentari menunjukkan bahwa informasi durasi aktivitas memiliki peran penting dalam mendeteksi sedentary time dan sedentary bout secara akurat. Salim et al. mengembangkan pendekatan untuk

mendeteksi durasi sedentari menggunakan perangkat wearable dan menunjukkan bahwa pengelolaan informasi waktu menjadi faktor penting dalam pemantauan sedentari [1]. Di sisi lain, Khattach et al. menunjukkan bahwa integrasi stream processing dan machine learning pipeline dapat mendukung analitik IoT secara real-time dengan latensi rendah [3]. Namun, dalam implementasi sistem real-time, terdapat tantangan tambahan berupa perbedaan antara timestamp ketika data dikirim oleh sensor dan timestamp ketika data selesai diproses atau disimpan ke database.

Permasalahan timestamp tersebut menjadi penting karena data sensor harus melalui beberapa tahap pemrosesan, seperti feature extraction, klasifikasi menggunakan model machine learning, dan penyimpanan ke database. Jika durasi sedentari dihitung berdasarkan waktu penyimpanan data, maka hasil pengukuran durasi dapat menjadi kurang akurat karena dipengaruhi oleh latensi proses sistem. Oleh karena itu, penelitian ini menghitung durasi sedentari menggunakan timestamp asli dari sensor atau sensor_event_time. Ketika pengguna pertama kali masuk ke kategori sedentary, sistem menyimpan waktu tersebut sebagai sedentary_start_time. Selanjutnya, durasi sedentari dihitung dari selisih antara sensor_event_time saat ini dan sedentary_start_time. Jika aktivitas berubah menjadi kategori light atau intense, nilai sedentary_start_time direset sehingga perhitungan durasi dimulai kembali ketika pengguna kembali ke kondisi sedentary.

Berdasarkan permasalahan tersebut, penelitian ini mengembangkan sistem klasifikasi dan monitoring aktivitas fisik real-time berbasis Random Forest untuk mendeteksi perilaku sedentari. Sistem yang dibangun mengintegrasikan wearable sensor, MQTT, Kafka, Spark Structured Streaming, MinIO, PostgreSQL, dan Tableau dalam satu pipeline data. Hasil prediksi aktivitas disimpan pada tabel operasional real-time untuk kebutuhan monitoring langsung, sedangkan data historis diintegrasikan ke dalam data mart menggunakan skema bintang yang terdiri atas fact_activity_daily_summary, dim_person, dim_activity, dan dim_time. Dengan pemisahan tersebut, sistem dapat mendukung kebutuhan monitoring real-time sekaligus analisis historis.

Tujuan penelitian ini adalah membangun sistem Human Activity Recognition berbasis Random Forest yang mampu mengklasifikasikan aktivitas fisik secara real-time, menghitung durasi sedentari

berdasarkan timestamp asli sensor, menghasilkan alert ketika durasi sedentari melewati ambang batas tertentu, serta menyediakan dashboard untuk pemantauan aktivitas dan analisis historis. Dengan pendekatan ini, sistem diharapkan dapat memberikan informasi aktivitas fisik yang lebih responsif, akurat, dan bermanfaat untuk mendukung pemantauan perilaku sedentari berbasis data wearable sensor.


Penulis	Permasalahan	Metode	Hasil
Salim et al.[1]	Deteksi sedentary time	Hidden Semi-Markov Model	Mampu mendeteksi sedentary bout dan durasi sedentary
Balli et al.[2]	HAR berbasis smartwatch	PCA = Random Forest	Random Forest memberikan akurasi klasifikasi yang baik
Khattach et al.[3]	Analitik IoT real-time	Stream Processing + ML Pipeline	Mendukung pemrosesan data real-time dengan latensi rendah
Armbrust et al.[4]	Integrasi data dan analitik	Lakehouse	Mendukung kebutuhan operasional dan analitik
Haresamudram et al.[5]	Survey HAR wearable	Literature Review	HAR wearable masih menjadi topik penelitian aktif
Ni et al.[6]	Multimodal	Literature Review	Multi-sensor

	wearable HAR		meningkatkan kualitas pengenalan aktivitas
--	--------------	--	--

MATERIALS AND METHODS

Penelitian ini menggunakan pendekatan pengembangan sistem berbasis data streaming untuk membangun sistem klasifikasi dan monitoring aktivitas fisik secara real-time. Sistem dikembangkan untuk menerima data sensor wearable secara berkala, melakukan ekstraksi fitur, mengklasifikasikan aktivitas fisik menggunakan algoritma Random Forest, menghitung durasi perilaku sedentari, menyimpan hasil pemrosesan ke dalam penyimpanan data, serta menampilkan hasil monitoring melalui dashboard.

Arsitektur sistem yang digunakan mengikuti pendekatan Kappa Architecture karena alur utama pemrosesan data dilakukan secara streaming. Data sensor dikirim melalui MQTT, kemudian diteruskan ke Kafka sebagai message broker. Selanjutnya, data dibaca oleh Spark Structured Streaming untuk dilakukan pemrosesan dan klasifikasi aktivitas. Data hasil streaming disimpan ke MinIO sebagai data lake, kemudian ditransformasikan ke PostgreSQL sebagai data mart untuk kebutuhan analisis historis. Hasil akhir divisualisasikan menggunakan Tableau agar pengguna dapat memantau aktivitas secara real-time maupun melihat ringkasan aktivitas secara agregat.




Gambar 1. Arsitektur Big Data

Sumber data yang digunakan berasal dari dataset aktivitas fisik berbasis sensor wearable. Sensor ditempatkan pada lima bagian tubuh, yaitu torso (T), right arm (RA), left arm (LA), right leg (RL),

dan left leg (LL). Setiap bagian tubuh memiliki tiga jenis sensor, yaitu accelerometer, gyroscope, dan magnetometer, yang masing-masing menghasilkan data pada sumbu x, y, dan z. Dengan demikian, data mentah yang digunakan terdiri atas 45 kolom sensor. Data tersebut merepresentasikan pergerakan pengguna pada berbagai aktivitas, seperti sitting, standing, walking, running, lying, serta aktivitas lain yang termasuk dalam kategori sedentary, light, dan intense.

Sebelum digunakan untuk proses klasifikasi, data sensor mentah melalui tahap ekstraksi fitur. Pada tahap ini, beberapa baris data sensor dikumpulkan dalam satu window atau segmen waktu tertentu. Dari setiap window tersebut dihitung fitur statistik seperti mean, standard deviation, minimum, maximum, skewness, dan kurtosis. Proses ini menghasilkan 360 fitur statistik yang digunakan sebagai input utama pada model Random Forest. Kolom tambahan seperti activity_id, activity_label, dan metadata lain digunakan sebagai informasi pendukung serta target label pada proses pelatihan model.

Pengumpulan data pada sistem real-time dilakukan dengan mensimulasikan pengiriman data sensor secara berkala menggunakan protokol MQTT. MQTT digunakan karena ringan dan sesuai untuk komunikasi data IoT. Data yang dikirim dari sensor kemudian diteruskan ke Kafka agar dapat diproses secara streaming oleh Spark Structured Streaming. Dengan mekanisme ini, sistem dapat menerima dan memproses data sensor secara kontinu.



Gambar 2. Konsep MQTT

Model klasifikasi yang digunakan dalam penelitian ini adalah Random Forest. Model dilatih menggunakan fitur statistik hasil ekstraksi dari data sensor wearable. Setelah model dilatih, data sensor baru yang masuk ke pipeline streaming diproses untuk menghasilkan label aktivitas dan kategori aktivitas. Keluaran utama dari proses klasifikasi meliputi predicted_activity_label, activity_category, confidence_score, sensor_event_time, predicted_at, dan stored_at.

Kategori aktivitas digunakan untuk membedakan aktivitas sedentary, light, dan intense.

Perhitungan durasi sedentari dilakukan menggunakan timestamp asli dari sensor, yaitu `sensor_event_time`. Pendekatan ini digunakan karena waktu data dikirim oleh sensor dapat berbeda dengan waktu data selesai diproses atau disimpan ke database akibat adanya latensi pada pipeline machine learning. Ketika aktivitas pengguna pertama kali masuk ke kategori sedentary, sistem menyimpan waktu tersebut sebagai `sedentary_start_time`. Selanjutnya, durasi sedentari dihitung dari selisih antara `sensor_event_time` saat ini dan `sedentary_start_time`. Jika aktivitas berubah ke kategori light atau intense, maka nilai `sedentary_start_time` direset dan durasi sedentari kembali menjadi nol.

Hasil klasifikasi aktivitas disimpan ke tabel operasional real-time, yaitu `realtime_activity_monitor`. Tabel ini digunakan untuk mendukung dashboard monitoring real-time karena menyimpan hasil prediksi terbaru, kategori aktivitas, confidence score, durasi sedentari, status alert, dan informasi latensi proses. Selain itu, sistem juga menyimpan state terakhir pengguna pada tabel `activity_state` untuk membantu proses perhitungan sedentary streak secara berkelanjutan.

Untuk kebutuhan analisis historis, data pada tabel real-time ditransformasikan menjadi data mart di PostgreSQL. Data mart dirancang menggunakan star schema dengan `fact_activity_daily_summary` sebagai tabel fakta utama. Tabel fakta ini memiliki grain satu baris untuk satu pengguna, satu tanggal, dan satu aktivitas. Measure yang disimpan meliputi `total_duration_minutes`, `avg_confidence_score`, `alert_count`, `max_sedentary_streak_minutes`, dan `prediction_count`. Tabel fakta tersebut terhubung dengan `dim_person`, `dim_activity`, dan `dim_time` sebagai tabel dimensi.

Analisis data dilakukan dalam tiga tahap utama. Tahap pertama adalah klasifikasi aktivitas fisik berdasarkan fitur statistik sensor menggunakan model Random Forest. Tahap kedua adalah monitoring durasi sedentari berdasarkan `sensor_event_time` dan `sedentary_start_time`. Tahap ketiga adalah transformasi data hasil prediksi ke dalam tabel operasional real-time dan data mart untuk mendukung dashboard. Dashboard yang dibangun terdiri atas dashboard monitoring aktivitas real-time, dashboard analisis aktivitas historis, dan dashboard monitoring performa model.

RESULTS AND DISCUSSION

4.1 Dataset and Feature Engineering Results

Data aktivitas fisik yang digunakan dalam penelitian ini diperoleh dari dataset UCI Machine Learning Repository yang berisi data sensor wearable pada beberapa bagian tubuh. Sensor ditempatkan pada lima posisi tubuh, yaitu torso (T), right arm (RA), left arm (LA), right leg (RL), dan left leg (LL). Setiap posisi tubuh memiliki tiga jenis sensor, yaitu accelerometer, gyroscope, dan magnetometer. Masing-masing sensor menghasilkan pengukuran pada sumbu x, y, dan z, sehingga data mentah yang digunakan terdiri atas 45 atribut sensor.

Untuk meningkatkan kemampuan model dalam membedakan aktivitas fisik, dilakukan proses feature engineering menggunakan pendekatan sliding window. Pada setiap window data, beberapa nilai statistik dihitung dari data sensor, seperti mean, standard deviation, minimum, maximum, skewness, dan kurtosis. Proses ekstraksi fitur ini menghasilkan 360 atribut statistik yang digunakan sebagai input utama pada model Random Forest. Selain itu, terdapat lima kolom tambahan berupa metadata dan label aktivitas, sehingga total kolom pada dataset akhir berjumlah 365 kolom.

Table 2. Dataset Transformation Results

Stage	Number of Features
Raw Sensor Data	45
Statistical Feature Extraction	360
Additional Metadata Columns	5
Total Dataset columns	365

Source: (Research Results, 2026)

Berdasarkan Tabel 2, proses feature engineering meningkatkan jumlah atribut dari 45 atribut sensor mentah menjadi 360 atribut statistik. Peningkatan jumlah atribut ini dilakukan karena pola aktivitas manusia tidak selalu dapat dikenali secara optimal hanya dari satu nilai sensor mentah. Fitur statistik digunakan untuk merepresentasikan pola pergerakan dalam suatu window data, sehingga model dapat menangkap karakteristik

aktivitas dengan lebih baik. Dengan demikian, hasil feature engineering menjadi tahap penting sebelum data digunakan dalam proses pelatihan dan klasifikasi menggunakan algoritma Random Forest.

4.2 Random Forest Classification Results

Model klasifikasi aktivitas fisik dibangun menggunakan algoritma Random Forest. Data yang digunakan sebagai masukan model merupakan hasil ekstraksi fitur statistik dari data sensor wearable. Sebanyak 360 fitur statistik digunakan sebagai input model, sedangkan label aktivitas digunakan sebagai target klasifikasi. Model ini digunakan untuk mengenali beberapa aktivitas fisik, seperti sitting, standing, lying, walking, running, dan aktivitas lain yang terdapat pada dataset.

Table 3. Random Forest Performance

Metric	Value
Accuracy	
Precision	
Recall	
F1-Score	

Source: (Research Results, 2026)

Berdasarkan Tabel 3, model Random Forest memperoleh nilai accuracy sebesar x, precision sebesar x, recall sebesar x, dan F1-score sebesar x. Hasil tersebut menunjukkan bahwa model mampu mengklasifikasikan aktivitas fisik berbasis data wearable sensor dengan performa yang baik. Nilai accuracy menunjukkan bahwa sebagian besar data berhasil diklasifikasikan dengan benar, sedangkan nilai precision yang relatif tinggi menunjukkan bahwa model cukup baik dalam menghasilkan prediksi yang tepat pada setiap kelas aktivitas.

Nilai recall sebesar 0.866 menunjukkan bahwa model mampu mengenali sebagian besar aktivitas aktual pada data pengujian. Sementara itu, nilai F1-score sebesar 0.856 menunjukkan adanya keseimbangan antara precision dan recall. Dengan demikian, Random Forest dapat digunakan sebagai model klasifikasi aktivitas fisik pada sistem monitoring real-time karena mampu menangani data fitur sensor yang berdimensi tinggi serta memberikan hasil klasifikasi yang stabil. Hasil ini

sejalan dengan penelitian Balli et al. [2] yang menunjukkan bahwa Random Forest merupakan salah satu metode yang efektif untuk Human Activity Recognition berbasis wearable sensor.

4.3 Real-Time Streaming Architecture


Setelah model Random Forest berhasil dilatih untuk melakukan klasifikasi aktivitas fisik, sistem diimplementasikan dalam arsitektur streaming real-time. Arsitektur ini digunakan agar data sensor yang dikirim secara periodik dapat langsung diproses, diklasifikasikan, disimpan, dan divisualisasikan melalui dashboard. Pendekatan yang digunakan dalam sistem ini mengacu pada Kappa Architecture karena alur utama pemrosesan data dilakukan melalui stream processing.

Pada tahap awal, data sensor wearable dikirim secara berkala menggunakan protokol MQTT. Data yang dikirim berisi nilai sensor dari beberapa bagian tubuh, yaitu torso (T), right arm (RA), left arm (LA), right leg (RL), dan left leg (LL). Setiap data sensor juga membawa informasi sensor_event_time yang menunjukkan waktu asli ketika data dihasilkan oleh sensor. Informasi timestamp ini digunakan sebagai acuan utama dalam perhitungan durasi sedentari.

Data dari MQTT kemudian diteruskan ke Kafka sebagai message broker. Kafka berfungsi sebagai penghubung antara sumber data sensor dan sistem pemrosesan streaming. Selanjutnya, Spark Structured Streaming membaca data dari Kafka untuk melakukan parsing data, feature preparation, klasifikasi aktivitas menggunakan model Random Forest, serta pembentukan hasil prediksi. Output dari proses ini berupa predicted_activity_label, activity_category, confidence_score, predicted_at, stored_at, dan prediction_latency_sec.

Hasil pemrosesan streaming disimpan ke MinIO sebagai data lake untuk menyimpan data hasil proses secara berkelanjutan. Selanjutnya, data tersebut ditransformasikan ke PostgreSQL sebagai data mart untuk mendukung kebutuhan analitik. Untuk monitoring real-time, hasil prediksi disimpan pada tabel realtime_activity_monitor. Tabel ini digunakan untuk menampilkan aktivitas terbaru, kategori aktivitas, confidence score, durasi sedentari, dan status alert. Sementara itu, untuk kebutuhan analisis historis, data diagregasi ke dalam fact_activity_daily_summary yang terhubung dengan dim_person, dim_activity, dan dim_time.

Figure 2. Real-Time Activity Monitoring Architecture



Source: (Research Results, 2026)

Arsitektur tersebut memungkinkan proses klasifikasi dan pemantauan aktivitas dilakukan

secara berkelanjutan. Setiap data sensor yang diterima akan diproses oleh Spark Structured Streaming untuk menghasilkan prediksi aktivitas terbaru. Hasil prediksi tersebut digunakan untuk menghitung durasi perilaku sedentari berdasarkan sensor_event_time. Jika durasi sedentari melebihi ambang batas yang telah ditentukan, sistem akan menghasilkan status alert. Dengan demikian, sistem dapat mendukung monitoring aktivitas fisik secara real-time sekaligus menyediakan data agregasi untuk analisis historis melalui dashboard.

4.4 Sedentary Behavior Monitoring Results

Salah satu kontribusi utama penelitian ini adalah mekanisme perhitungan durasi sedentary menggunakan timestamp asli sensor. Pendekatan ini dipilih karena timestamp saat data diterima sensor dapat berbeda dengan timestamp saat data berhasil disimpan ke database akibat adanya latensi proses machine learning.

Table 4. Sedentary Monitoring Example

Sensor Timestamp	Activity	Sedentary Duration(Minute)	Alert Status

Source: (Research Results, 2026)

Perhitungan dilakukan menggunakan waktu pertama kali pengguna memasuki kategori sedentary (*sedentary_start_time*). Ketika aktivitas berubah menjadi kategori lain, nilai tersebut direset sehingga durasi dihitung kembali dari awal. Dengan pendekatan ini, sistem dapat memberikan estimasi durasi sedentary yang lebih akurat dibandingkan metode yang hanya mengandalkan waktu penyimpanan data.

Hasil ini sejalan dengan penelitian Salim et al. [1] yang menunjukkan bahwa informasi durasi aktivitas memiliki peran penting dalam mendeteksi sedentary bout secara tepat.


4.5 Dashboard Implementation

Untuk mendukung kebutuhan monitoring dan analisis, sistem menyediakan tiga dashboard utama.

Table 5. Dashboard Components

Dashboard	Function
Real-Time Dashboard	Monitoring aktivitas dan alert secara langsung
Sedentary Monitoring Dashboard	Monitoring durasi sedentary pengguna
Model Performance Dashboard	Monitoring performa model Random Forest

Source: (Research Results, 2026)



Dashboard real-time digunakan untuk menampilkan aktivitas pengguna yang sedang berlangsung beserta status peringatan. Dashboard monitoring sedentary menampilkan durasi perilaku sedentary yang sedang berlangsung. Sementara itu, dashboard performa model digunakan untuk memantau metrik evaluasi klasifikasi seperti accuracy, precision, recall, dan F1-score.

4.6 Data Warehouse Design Discussion

Untuk mendukung kebutuhan analitik historis, penelitian ini memisahkan data streaming real-time dan data agregasi.

Table 6. Data Storage Architecture

Storage Layer	Purpose
Streaming Table	Operational Monitoring

Fact Table	Historical Analytics
Dimension Table	Supporting Information

Source: (Research Results, 2026)

Pendekatan ini mengikuti prinsip pemisahan antara kebutuhan operasional dan kebutuhan analitik sebagaimana dijelaskan dalam konsep Lakehouse oleh Armbrust et al. [4]. Data streaming digunakan untuk monitoring real-time, sedangkan fact table digunakan untuk menyimpan informasi agregasi seperti jumlah alert harian, total waktu sedentary, dan rata-rata durasi sedentary.

CONCLUSION

Penelitian ini berhasil mengembangkan sistem klasifikasi dan pemantauan aktivitas fisik secara real-time menggunakan data wearable sensor dan algoritma Random Forest. Sistem yang diusulkan mampu melakukan klasifikasi aktivitas fisik secara berkelanjutan serta memantau durasi perilaku sedentary menggunakan timestamp asli sensor sehingga mengurangi kesalahan perhitungan akibat latensi proses machine learning. Selain itu, penerapan mekanisme alert memungkinkan sistem memberikan peringatan ketika durasi sedentary melebihi ambang batas yang telah ditentukan. Arsitektur yang memisahkan tabel streaming real-time dan tabel fakta agregasi juga memungkinkan kebutuhan monitoring operasional dan analisis historis berjalan secara bersamaan. Hasil penelitian menunjukkan bahwa integrasi wearable sensor, machine learning, stream processing, dan data warehouse dapat digunakan untuk mendukung pemantauan aktivitas fisik yang lebih akurat dan responsif guna membantu upaya pencegahan risiko kesehatan akibat perilaku sedentary yang berkepanjangan.

REFERENCE

Sedentary Behavior & Monitoring

[1] A. Salim, C. J. Brakenridge, D. H. Lekamlage, E. Howden, R. Grigg, H. T. Dillon, H. D. Bondell, J. A. Simpson, G. N. Healy, N. Owen, D. W. Dunstan, and E. A. H. Winkler, "Detection of sedentary time and bouts using consumer-grade wrist-worn devices: a hidden semi-Markov model," *BMC Medical Research Methodology*, vol. 24, art. no. 222, 2024.

Real-Time Streaming & IoT Analytics

[2] O. Khattach, O. Moussaoui, and M. Hassine, "End-to-End Architecture for Real-Time IoT Analytics and Predictive Maintenance Using Stream Processing and ML Pipelines," *Sensors*, vol. 25, no. 9, art. no. 2945, 2025.

[7] M. Bock, H. Kuehne, K. Van Laerhoven, and M. Moeller, "WEAR: An Outdoor Sports Dataset for Wearable and Egocentric Activity Recognition," 2023.

Data Warehouse / Lakehouse

[3] M. Armbrust, A. Ghodsi, R. Xin, and M. Zaharia, "Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics," in *Proceedings of CIDR 2021*, 2021.

Random Forest & HAR

[4] S. Balli, E. A. Sağbaş, and M. Peker, "Human Activity Recognition from Smartwatch Sensor Data Using a Hybrid of Principal Component Analysis and Random Forest Algorithm," *Measurement and Control*, vol. 52, no. 1–2, pp. 37–45, 2019.

Wearable Human Activity Recognition

[5] H. Haresamudram, C. I. Tang, S. Suh, P. Lukowicz, and T. Ploetz, "Past, Present, and Future of Sensor-Based Human Activity Recognition Using Wearables: A Surveying Tutorial on a Still Challenging Task," 2024.

[6] J. Ni, H. Tang, S. T. Haque, Y. Yan, and A. H. H. Ngu, "A Survey on Multimodal Wearable Sensor-based Human Action Recognition," 2024.